

基于卡尔曼滤波的动态轨迹预测算法

乔少杰¹ 韩楠² 朱新文³ 舒红平⁴ 郑皎凌⁴ 元昌安⁵

(1. 成都信息工程大学网络空间安全学院 四川成都 610225; 2. 成都信息工程大学管理学院 四川成都 610103;
3. 西南交通大学信息科学与技术学院 四川成都 611756; 4. 成都信息工程大学软件工程学院 四川成都 610225;
5. 广西师范学院计算机与信息工程学院 广西南宁 541004)

摘要: 基于拟合的传统轨迹预测算法已无法满足高精度和实时性预测要求. 提出基于卡尔曼滤波的动态轨迹预测算法, 对移动对象动态行为进行状态估计, 利用前一时刻的估计值和当前时刻的观测值更新对状态变量的估计, 进而对下一时刻的轨迹位置预测. 大量真实移动对象数据集上的实验结果表明: GeoLife 数据集上基于卡尔曼滤波的轨迹预测算法的平均预测误差(预测轨迹点与实际轨迹点的均方根误差)为 12.5 米; 与基于轨迹拟合的轨迹预测算法相比, T-Drive 数据集预测误差平均下降了 555.4 米, 预测准确率提升了 7.1%. 在保证预测时效性前提下, 基于卡尔曼滤波的动态轨迹预测算法解决了轨迹预测精度较低的问题.

关键词: 移动对象数据库; 状态估计; 轨迹预测; 卡尔曼滤波; 轨迹拟合

中图分类号: TP311 文献标识码: A 文章编号: 0372-2112 (2018) 02-0418-06

电子学报 URL: <http://www.ejournal.org.cn>

DOI: 10.3969/j.issn.0372-2112.2018.02.022

A Dynamic Trajectory Prediction Algorithm Based on Kalman Filter

QIAO Shao-jie¹, HAN Nan², ZHU Xin-wen³, SHU Hong-ping⁴, ZHENG Jiao-ling⁴, YUAN Chang-an⁵

(1. School of Cybersecurity, Chengdu University of Information Technology, Chengdu, Sichuan 610225, China;

2. School of Management, Chengdu University of Information Technology, Chengdu, Sichuan 610103, China;

3. School of Information Science and Technology, Southwest Jiaotong University, Chengdu, Sichuan 611756, China;

4. School of Software Engineering, Chengdu University of Information Technology, Chengdu, Sichuan 610225, China;

5. School of Computer and Information Engineering, Guangxi Teachers Education University, Nanning, Guangxi 541004, China)

Abstract: Traditional fitting-based trajectory prediction algorithms cannot meet the requirements of high accuracy and real-time prediction. A dynamic Kalman filter based TP approach was proposed, which performs state estimation of dynamic behavior with regard to moving objects, updates the state variable estimation value based on the estimation of the previous and current observation states, in order to infer the next location of moving objects. Extensive experiments are conducted on real datasets of moving objects and the results demonstrate that the average prediction error (root mean square error between the predicted location and the actual location) of the TP algorithm based on Kalman filter is around 12.5 meters on the GeoLife datasets. The prediction error is reduced by about 555.4 meters by compared to the fitting-based TP algorithms, and the prediction accuracy is increased by 7.1% on the T-Drive datasets as well. The dynamic TP approach based on Kalman filter can handle the problem of low prediction accuracy with the guarantee of efficient time performance.

Key words: moving objects databases; state estimation; trajectory prediction; Kalman filter; trajectory fitting

1 引言

在移动对象轨迹预测高精度要求的应用领域中, 基于轨迹拟合的传统预测算法已无法精准地预测出运

动行为动态变化的移动对象的轨迹位置^[1], 将卡尔曼滤波算法^[2]应用于移动对象动态轨迹预测的优势主要体现在如下两个方面:

(1) 卡尔曼滤波算法尤其适用于运动状态频繁变

收稿日期: 2016-07-15; 修回日期: 2017-10-09; 责任编辑: 马兰英

基金项目: 国家自然科学基金(No. 61772091, No. 61363037); 教育部人文社会科学研究规划基金(No. 15YJAZH058); 教育部人文社会科学研究青年基金(No. 14YJCZH046); 四川省教育厅资助科研项目(No. 14ZB0458); 成都信息工程大学引进人才科研启动项目(No. KYTZ201715, No. KYTZ201750); 四川高校科研创新团队建设计划资助(No. 18TD0027); 成都信息工程大学中青年学术带头人科研基金(No. J201701)

化、具有不确定性和不同运动模式的轨迹数据,能够对系统状态进行最优估计,能够实现实时运行状态的估计和预测,且适用于有限维度线性和非线性的时空轨迹。

(2) 动态轨迹预测对预测结果的实时性和准确度具有非常高的要求,预测偏差过大或者预测位置点的不精确会导致预测失效。将卡尔曼滤波算法应用于轨迹预测具有实时性高的优势,对频繁变换运动状态的移动对象具有较高的自适应性,是一种普适的机器学习方法。

2 相关工作

当前国内外针对移动对象的轨迹预测的研究,已经取得了系列的研究成果。在挖掘频繁轨迹模式方面,Ying 等人^[3]通过挖掘同类用户的群体行为模式并结合轨迹的语义特征来预测未来位置信息。Qiao 等人^[4]通过构建轨迹频繁模式树挖掘频繁轨迹模式。Gambs^[5]提出高阶马尔可夫模型用于预测移动对象位置,预测精度可以达到 95% 以上,但是计算开销比较大。Qiao 等人^[6]将隐马尔可夫模型 HMM 应用于移动对象轨迹预测,但没有考虑大数据环境下算法的运行时间性能问题。

大多数轨迹预测方法基于轨迹的地理特性,而 Zheng 等人^[7]对个体的旅行经历和兴趣爱好等语义信息建模预测个体感兴趣的位置点。Qiao 等人^[8]利用高斯混合模型对移动对象的复杂运动行为模式建模,计算不同运动模式的概率分布情况。Song 等人^[9]通过计算轨迹的信息熵证明人类动态运动行为具有 93% 的可预测性。Pan 等人^[10]提出了基于多元正态分布的最佳线性预测器,不足在于预测结果往往会产生延迟。Zhou 等人^[11]通过动态选择参考轨迹,并基于少量的参数构建精准的预测模型。

3 基于卡尔曼滤波的动态轨迹预测算法

3.1 基本概念及问题描述

已知移动对象的轨迹数据集 T 存储大量运动对象在不同时刻下的位置点信息,根据时间上的有序形式组成的位置点集合称为轨迹 Trj 。由 n 条轨迹组成的轨迹数据集用 $T = \{Trj_1, Trj_2, \dots, Trj_n\}$ 表示。

定义 1(轨迹矢量集) 对欧式空间二维平面 x 轴和 y 轴方向进行建模,利用两个方向上的矢量表示轨迹数据: $T = \{Trj_1, Trj_2, \dots, Trj_n\} = \{(\mathbf{p}_x^1, \mathbf{p}_y^1), (\mathbf{p}_x^2, \mathbf{p}_y^2), \dots, (\mathbf{p}_x^n, \mathbf{p}_y^n)\} = \{(\mathbf{p}_x^1, \mathbf{p}_x^2, \dots, \mathbf{p}_x^n)^T, (\mathbf{p}_y^1, \mathbf{p}_y^2, \dots, \mathbf{p}_y^n)^T\}$ 其中, $\mathbf{p}_x^i = (x_{i1}, x_{i2}, \dots, x_{id})^T$ 表示第 i 条轨迹在 x 方向上的投影矢量集, $\mathbf{p}_y^i = (y_{i1}, y_{i2}, \dots, y_{id})^T$ 表示第 i 条轨迹在 y 方向上的投影矢量集, $(\mathbf{p}_x^i, \mathbf{p}_y^i)$ 称为轨迹 Trj_i 的矢量集, T

称为轨迹矢量集。

定义 2(卡尔曼滤波) 一种利用线性系统状态方程以及观测方程: $X(k+1) = A(k)X(k) + T(k)W(k)$, $Z(k) = H(k)X(k) + V(k)$, 通过以最小均方差 $J = E[(x_{k+1} - x'_{k+1})(x_{k+1} - x'_{k+1})^T]$ 为准则,根据滤波方程滤波出最优状态估计值,如下所示:

$$X(k+1|k+1)$$

$$= X(k+1|k) + K(k+1)[Z(k+1) - Z(k+1|k)]$$

其中 $X(k+1)$ 表示 $k+1$ 时刻下的状态值, $A(k)$ 为状态转移矩阵, $T(k)$ 为干扰转移矩阵, $W(k)$ 表示运动模型的系统状态噪声, $Z(k)$ 表示观测向量, $H(k)$ 为观测矩阵, $V(k)$ 为观测噪声, x'_{k+1} 表示 $k+1$ 时刻下最优状态估计值, $K(k+1)$ 为 $k+1$ 时刻的增益矩阵。

定义 3(预测误差) 对于预测轨迹点与实际轨迹点的几何空间误差采用公式(1)所示的均方根误差 RMSE 来计算:

$$RMSE = \frac{\sum_{i=1}^k \sqrt{(x'_i - x_i)^2 + (y'_i - y_i)^2}}{k} \quad (1)$$

其中 (x_i, y_i) 表示实际轨迹点的位置, (x'_i, y'_i) 表示预测轨迹点的位置信息, k 表示预测轨迹点的数量。

定义 4(预测命中) 当轨迹预测完成时,根据均方根误差 RMSE 与给定的阈值的大小关系确定轨迹预测结果是否准确,当均方根误差 RMSE 值小于阈值则属于命中;否则,属于没有命中。

3.2 算法工作原理

卡尔曼滤波(Kalman Filtering)^[2]通过系统输入输出观测数据对系统状态进行最优估计,尤其适用于运动状态频繁变化运动行为的预测,能够实现实时预测。卡尔曼滤波动态轨迹预测系统的状态方程(公式 2)和观测方程(公式 3)如下所示:

$$X(k+1) = A(k)X(k) + T(k)W(k) \quad (2)$$

$$Z(k) = H(k)X(k) + V(k) \quad (3)$$

其中 $X(k)$ 表示系统状态向量,描述了在 k 时刻下运动对象状态矢量; $A(k)$ 表示状态转移矩阵,用于描述由前一时刻到当前时刻下的运动状态转移方式; $T(k)$ 为干扰转移矩阵; $W(k)$ 表示运动模型的系统状态噪声,其统计特性与白噪声或高斯噪声相似; $Z(k)$ 表示观测向量,描述了 k 时刻的观测值; $H(k)$ 为观测矩阵,对于单测量系统 $H(k)$ 为 1×1 维的矩阵; $V(k)$ 为运动估计过程中产生的观测噪声。

假设系统噪声 $W(k)$ 与观测噪声 $V(k)$ 是相互独立的高斯白噪声,其协方差分别是 Q 和 R ,其统计特性如下所示:

$$E[W(k)W(k)^T] = \begin{cases} Q(k), & i = k \\ 0, & i \neq k \end{cases}$$

$$E[V(k) V(k)^T] = \begin{cases} R(k), & i = k \\ 0, & i \neq k \end{cases}$$

$$E[W(k) V(k)^T] = 0$$

卡尔曼滤波算法核心是运用递归算法来达到最优状态估计的估计模型,利用前一时刻的估计值和现时刻的观测值来更新当前状态变量的估计。基于前 k 个观测值得出 k 时刻下的最优状态估计 $x'(k)$,计算最小方差计算的策略如公式(4)所示:

$$J = E[(x_k - x'_k)(x_k - x'_k)^T] \quad (4)$$

在随机线性离散卡尔曼滤波周期过程中存在两个不同更新过程,分别是时间更新过程和观测更新过程。时间更新过程根据前一时刻最优状态估计预测出当前时刻下的状态,同时更新当前预测状态的协方差 $P(k+1, k)$,时间更新方程如公式(5)~(6)所示。

$$X(k+1, k) = A(k) X(k, k) \quad (5)$$

$$Z(k+1, k) = H(k) X(k+1, k) \quad (6)$$

当预测出轨迹点之后,需要利用观测值进行线性拟合出最优估计轨迹点位置,即根据观测值和预测值通过观测更新方程来推测出最优估计点,观测更新方程表达式如下面公式(7)和公式(8)所示。

$$B(k+1) = Z(k+1) - Z(k+1, k) \quad (7)$$

$$X(k+1, k+1) = X(k+1, k) + K(k+1) B(k+1) \quad (8)$$

以上方程中除了滤波增益矩阵 K 未知,其他的参数均是已知的,所以接下来讨论增益矩阵 K 。增益矩阵 K 是基于状态噪声协方差以及观测噪声协方差得出的,如公式(9)~(11)所示;同时给出下一时刻最优状态估计协方差更新公式如公式(12)所示。

$$P(k+1, k) = A(k) P(k, k) A(k)^T + T(k) Q(k) T(k)^T \quad (9)$$

$$S(k+1) = H(k+1) P(k+1, k) H(k+1)^T + R(k+1) \quad (10)$$

$$K(k+1) = P(k+1, k) H(k+1)^T S(k+1)^{-1} \quad (11)$$

$$P(k+1, k+1) = P(k+1, k) - K(k+1) S(k+1) K(k+1)^T \quad (12)$$

其中 $Q(k)$ 表示系统噪声 $W(k)$ 的对称非负定方差矩阵, $R(k)$ 是观测噪声 $V(k)$ 的对称正定方差矩阵, $P(k, k)$ 为误差方差阵, $P(k+1, k)$ 为预测状态 $X(k+1, k)$ 误差方差阵, $K(k)$ 为滤波增益矩阵。

预测过程中,首先根据上面滤波过程得到的初始状态估计值以及协方差阵以及公式(13),得到增益矩阵 K 如下所示。

$$K(k) = A(k) P(k, k-1) H(k)^T [H(k) \cdot P(k, k-1) H(k)^T + R(k)]^{-1} \quad (13)$$

得到增益矩阵 K 之后,根据最优预测估计方程公式

(14),得到下一时刻预测值 $X(k+1, k)$,同时更新估计误差方差阵 $P(k+1, k)$,如下所示。

$$X(k+1, k) = A(k) X(k, k-1) + K(k) [Z(k) - H(k) X(k, k-1)] \quad (14)$$

$$P(k+1, k) = A(k) P(k, k-1) A(k)^T - A(k) P(k, k-1) \cdot H(k)^T [H(k) P(k, k-1) H(k)^T + R(k)]^{-1} H(k) P(k, k-1) A(k)^T + T(k) Q(k) T(k)^T \quad (15)$$

根据上面的公式得到下一时刻的最优预测值,完成单步预测过程。如果预测 n 步时,则可以迭代预测 n 次,即可完成 n 步预测。

3.3 轨迹预测算法描述

基于卡尔曼滤波的轨迹预测算法如算法1所示。详细步骤为:

算法1 基于卡尔曼滤波的轨迹预测算法

输入: 移动对象的轨迹数据集 $T = \{Tr_{j1}, Tr_{j2}, \dots, Tr_{jn}\}$ 。

输出: 轨迹预测误差均值 RMSE。

1. $D = \text{trajectPretreatment}(T)$;
2. $\text{initParameters}()$;
3. $\text{state} = \text{getCurrentState}(D)$;
4. **for** $i = 1$ to k
5. $p' = \text{kalmanPredict}(D)$;
6. $e[i] = \text{getRMSE}(p, p')$;
7. **end for**
8. $\text{RMSE} = (\sum_{i=1}^k e[i]) / k$;
9. **Output** RMSE;

(1) 分析移动对象的轨迹数据集,对数据进行修正、筛选以及 xy 坐标转换完成预处理操作(第1行);

(2) 根据系统的状态方程和观测方程确定的运动模型参数,并初始化 A 、 Q 、 R 等参数(第2行)。

(3) 已知初始时刻(即 $i=0$ 时刻)下的最优状态估计值 $X(0, 0)$ 以及估计误差方差阵 $P(0, 0)$,便可以根据系统状态方程预测出下一时刻(即 $i=1$ 时刻)移动对象预测值 $X(1, 0)$,同时得到估计误差的协方差阵 $P(1, 0)$;然后,根据 $i=1$ 时刻下的观测值 $Z(1)$ 得到 $i=1$ 时刻下的最优状态估计值 $X(1, 1)$,以及最优估计误差的协方差阵 $P(1, 1)$,完成一步滤波;依次迭代得到前一时刻的最优状态估计 $X(n-1, n-1)$,完成滤波过程(第3行)。

(4) 根据前面得到的前一时刻的最优状态估计 $X(n-1, n-1)$,以及当前时刻的观测值预测出第 $n+1$ 时刻下的轨迹点位置(第5行),预测点 p' 与真实轨迹点 p 进行比较,计算出预测误差(第6行);依次重复 k 次操作完成未来 k 步轨迹点的预测,最后计算并输出预

测误差均值(第 8~9 行)。

4 实验分析

4.1 数据集描述

实验采用经典移动对象轨迹数据集: GeoLife 数据集^[12]以及出租车轨迹数据集 T-Drive^[13]。实验中硬件环境: 主频为 2.4GHz 的 Intel Core I3 CPU 上, 内存为 4GB, 操作系统为 Windows 7, 集成开发环境为: Eclipse + JDK1.6。实验参数设置如表 1 所示。

表 1 参数设置

参数	值
移动对象轨迹数据集	GeoLife, T-Drive
移动对象轨迹总数	17621, 10355
测试轨迹数量	1000, 2000, 3000, 4000, ..., 10000
历史轨迹输入长度	10, 20, 30, 40, 50
预测轨迹长度(步数)	1, 2, 3, 4, 5
预测误差阈值	25m
观测噪声协方差矩阵 R	$\begin{bmatrix} 10 & 0 & 0 \\ 0 & 10 & 0 \\ 0 & 0 & 10 \end{bmatrix}$
系统噪声协方差矩阵 Q	$\begin{bmatrix} 100 & 0 & 0 & 0 \\ 0 & 100 & 0 & 0 \\ 0 & 0 & 100 & 0 \\ 0 & 0 & 0 & 100 \end{bmatrix}$

实验对比算法包括: 基于卡尔曼滤波的动态轨迹预测算法、朴素卡尔曼滤波预测算法, 文献[8]提出的基于隐马尔可夫模型的轨迹预测算法, 基于轨迹拟合的 N 点线性逼近算法、 N 点二次多项式平方预测算法。朴素卡尔曼滤波与基于卡尔曼滤波的预测算法在预测过程不同。朴素算法直接通过状态方程 $X(k+1) = A(k)X(k)$ 进行预测, 而基于卡尔曼滤波算法: 利用观测值重新计算增益, 从而预测下一步, 依次利用前一刻的观测迭代 k 步, 完成 k 步预测。

基于隐马尔可夫模型的轨迹预测算法构建移动对象运动状态转换的隐马尔可夫链, 根据当前状态预测下一位置状态。最后两种预测算法通过选取距离预测值较近的 N 点测量值来预测目标, 所以预测步长选取范围很大程度上影响着预测效果。本文中对于基于轨迹拟合的轨迹预测算法选取的步长为 5 步。

4.2 预测准确性和时间性能分析

本节对 4 种算法在不同测试集规模在 1000~10000 条下进行对比实验, 采用定义 3 预测误差进行评价, 实验结果取每种测试集下所有轨迹预测误差 RMSE 及准确率平均值评价预测准确性。

第一组实验: GeoLife 数据集规模较大, 为了保证消除特定训练数据和测试数据对实验结果的影响, 本文随机选取 1000~10000 条轨迹数据, 分别对 4 种算法进

行训练和预测。从预测误差、预测准确率和预测时间上证明所提算法的优势。结果如图 1~图 3 所示。

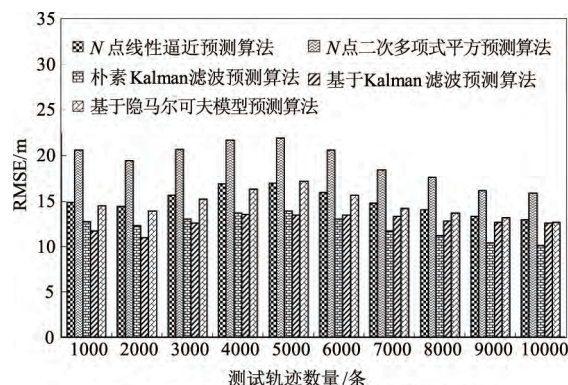


图1 GeoLife数据集下算法预测误差对比




图2 GeoLife数据集下算法预测准确率比较

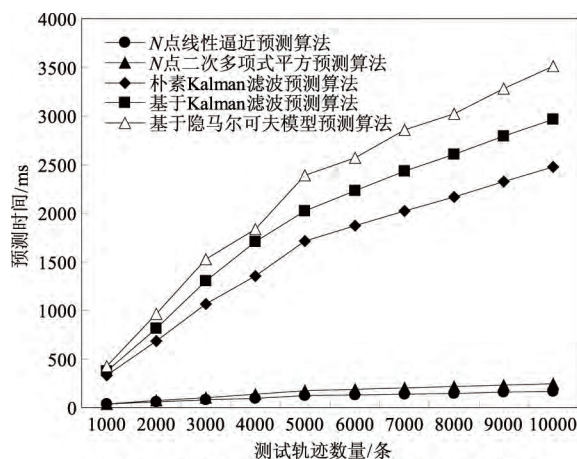


图3 GeoLife数据集下算法预测运行时间比较

GeoLife 数据集上实验结果表明:

(1) 如图 1~图 2 所示, 对于预测准确性分析得到: 与另外两种基于轨迹拟合的预测算法相比, 基于卡尔曼滤波的轨迹预测算法的误差最小, 算法的预测误差平均为 12.5m, 准确性在 88% 上下波动。原因在于基于卡尔曼滤波的轨迹预测算法对于运动行为相对稳定的移动对象, 只需经过一段短暂的滤波初期阶段之后,

预测效果较好,并且误差比较小.基于隐马尔可夫模型预测算法的预测误差略高于基于卡尔曼滤波的轨迹预测算法,预测准确率略低于基于卡尔曼滤波的轨迹预测算法,且这两项指标上均优于 N 点线性逼近算法和 N 点二次多项式平方预测算法.原因在于对于速度任意变化的移动对象,其运动状态具有不确定性,而马尔可夫模型本质是概率统计模型,导致其预测偏差高于且预测准确性低于不受运动状态影响的基于卡尔曼滤波的轨迹预测算法.

(2) 对于运行时间分析,如图3所示,朴素卡尔曼滤波预测算法与基于卡尔曼滤波的轨迹预测算法的时间代价均很大,因为基于卡尔曼滤波的轨迹预测算法需要对训练轨迹数据的多次迭代得出当前时刻的最优状态估计,而基于轨迹拟合的预测算法只是需要根据前5步训练轨迹数据得出目标运动规则.从图3中可以发现:随着测试轨迹数递增,基于卡尔曼滤波的轨迹预测算法的时间代价递增减缓,进而证明了本文所提方法具有可伸缩性和稳定性.此外,相比于其他四种预测算法,基于隐马尔可夫模型预测算法的预测时间最长.原因在于其需要构建移动对象隐状态之间的概率转换矩阵及隐状态到观测状态之间的概率转换矩阵,这两个操作非常耗时.

第二组实验:为了保证不让某些时间间隔较长的轨迹数据集影响算法的预测精度,本文将T-Drive数据集中时间序列超过5秒的轨迹数据集去除.实验中随机选取1000~10000条轨迹数据,结果如图4~图6所示.




图4 T-Drive数据集下预测误差对比

通过分析T-Drive数据集上的实验结果得到如下结论:(1)对于预测准确性分析,如图4~图5所示,由于汽车机动性较强,导致T-Drive数据集里轨迹点波动较大,进而预测误差非常大.与 N 点线性逼近算法和 N 点二次多项式平方预测算法相比,基于卡尔曼滤波的预测算法的预测误差最小,预测误差平均下降了555.4米,预测准确率提升了7.1%.基于隐马尔可夫模型的




图5 T-Drive数据集下预测准确率比较




图6 T-Drive数据集下算法预测运行时间比较

预测算法在速度随机变化的轨迹数据上预测效果不佳,本节实验也说明了这一点,其预测偏差略高于且预测准确性略低于基于卡尔曼滤波的预测算法.(2)对于运行时间分析,如图6所示,与GeoLife数据集得出的结论一致,这里不再赘述.

5 结论及未来工作

本文利用卡尔曼滤波模型对轨迹位置点进行连续预测,通过采用系统的状态空间模型以及观测模型,以最小均方差为准则估计动态系统的状态,进而实现准确和高效的位置预测.所提模型的优势在于预测对象过程中具有无偏、稳定和最优的特性.移动对象轨迹预测的研究仍然存在如下问题有待进一步研究,如:对移动对象的未来长时间轨迹位置的预测,保证预测的实时性及预测算法充分考虑影响对象运动行为的主客观因素等研究.

参考文献


- [1] Meng X, Ding Z, Xu J. Moving Objects Management: Models, Techniques and Applications [M]. Springer Press,

2014. 105 – 112.
- [2] Kalman R E. A new approach to liner filtering and prediction problems[J]. Journal of Basic Engineering ,1960 ,82D (1) : 35 – 45.
- [3] Ying J J ,Lee W ,Weng T ,Tseng V S. Semantic trajectory mining for location prediction [A]. Proceedings of the 19th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems [C]. New York: ACM , 2011. 34 – 43.
- [4] Qiao S ,Han N ,Zhu W ,Gutierrez L A. TraPlan: an effective three-in-one trajectory prediction model in transportation networks [J]. IEEE Transactions on Intelligent Transportation Systems 2015 ,16(3) : 1188 – 1198.
- [5] Gambs S ,Killijian M ,Cortez D P ,Miguel N. Next place prediction using mobility Markov chains [A]. Proceedings of the 1st Workshop on Measurement ,Privacy and Mobility [C]. New York: ACM 2012. 3: 1 – 6.
- [6] Qiao S ,Shen D ,Wang X ,Han N ,Zhu W. A self-adaptive parameter selection trajectory prediction approach via hidden Markov models [J]. IEEE Transactions on Intelligent Transportation Systems 2015 ,16(1) : 284 – 296.
- [7] Zheng Y ,Zhang L ,Xie X ,Ma W. Mining interesting locations and travel sequences from GPS trajectories [A]. Proceedings of the 18th International Conference on World Wide Web [C]. New York: ACM 2009. 791 – 800.
- [8] 乔少杰 ,金琨 ,韩楠 ,唐常杰 ,格桑多吉 ,Gutierrez Louis Alberto. 一种基于高斯混合模型的轨迹预测算法 [J]. 软件学报 2015 26(5) : 1048 – 1063.
Qiao S ,Jin K ,Han N ,Tang C ,Gesangduoji ,Gutierrez L A. Trajectory prediction algorithm based on Gaussian mixture model [J]. Journal of Software 2015 26(5) : 1048 – 1063. (in Chinese)
- [9] Song C ,Qu Z ,Blumm N ,Barabsi A. -L. Limits of predictability in human mobility [J]. Science ,2010 ,327(5968) : 1018 – 1021.
- [10] Pan T ,Sumalee A ,Zhong R ,Indra-payoong N. Short-term traffic state prediction based on temporal-spatial correlation [J]. IEEE Transactions on Intelligent Transportation Systems 2013 ,14(3) : 1242 – 1254.
- [11] Zhou J ,Tung K H ,Wu W ,Ng W S. A “semi-lazy” approach to probabilistic path prediction in dynamic environments [A]. Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining [C]. New York: ACM 2013. 748 – 756.
- [12] Zheng Y ,Xie X ,Ma W. Geolife: A collaborative social networking service among user ,location and trajectory [J]. IEEE Data Engineering Bulletin ,2010 ,33(2) : 32 – 40.
- [13] Yuan J ,Zheng Y ,Xie X ,Sun G. T-Drive: enhancing driving directions with taxi drivers’ intelligence [J]. IEEE Transactions on Knowledge and Data Engineering 2013 , 25(1) : 220 – 232.

作者简介



乔少杰 男,1981 年生于黑龙江省. 2009 年毕业于四川大学,获博士学位. 现为成都信息工程大学网络空间安全学院教授. 主要研究方向为轨迹大数据挖掘、轨迹预测等.
E-mail: sjqiao@cuit.edu.cn



韩楠(通信作者) 女,1984 年生于陕西省. 2012 年毕业于成都中医药大学,获博士学位. 现为成都信息工程大学管理学院讲师. 主要研究方向为轨迹预测、数据挖掘等.
E-mail: hannan@cuit.edu.cn