

基于特征损失的医学图像超分辨率重建

邢晓羊^{1,2}, 魏敏^{1,2}, 符颖^{1,2}

XING Xiaoyang^{1,2}, WEI Min^{1,2}, FU Ying^{1,2}

1. 成都信息工程大学 计算机学院, 成都 610225

2. 成都信息工程大学 图形图像与空间信息协同创新中心, 成都 610225

1. School of Computer Science, Chengdu University of Information and Technology, Chengdu 610225, China

2. Collaborative Innovation Center for Image and Geospatial Information, Chengdu University of Information and Technology, Chengdu 610225, China

XING Xiaoyang, WEI Min, FU Ying. Super-resolution reconstruction of medical images using feature-based loss. Computer Engineering and Applications, 2018, 54(20): 202-207.

Abstract: High-resolution Magnetic Resonance (MR) images can provide a clearer anatomical image to facilitate early diagnosis of the disease. However, the inherent defects of medical imaging system make the acquisition of high-resolution medical images face many problems, and one of the methods to solve these problems is to use the super-resolution reconstruction technique. In view of the problem of medical image super-resolution reconstruction, a feedforward full connection convolution neural network is designed, which includes five-layer convolution layer and five residual blocks, and the loss function based on feature is also used to solve the problem caused by mean square error loss function which cannot meet the human visual sense. This method realizes the image 4 times magnification reconstruction in the network and avoids the checkerboard artifacts, which are often occurred when using deconvolution layers to up-sample images. The effectiveness of the method is verified by experiments, and both the visual and numerical results are improved.

Key words: medical image; super-resolution reconstruction; convolution neural network; feature-based loss

摘 要: 高分辨率的磁共振图像可以提供更加清晰的解剖图像, 从而促进疾病的早期诊断。但是医疗成像系统的固有缺陷, 使得高分辨率医学图像的获取面临许多问题, 解决这类问题的方法之一就是使用超分辨率重建技术。针对医学图像超分辨率重建问题, 设计一个前馈全连接卷积神经网络, 网络包括五层卷积层和五个残差块, 并且使用基于特征的损失函数, 解决了使用均方误差损失函数不符合人视觉感的问题。该方法在网络内部实现图像4倍放大重建, 避免了使用反卷积层上采样时出现的棋盘伪影。通过实验验证了方法的有效性, 在视觉和数值结果上都有所提高。

关键词: 医学图像; 超分辨率重建; 卷积神经网络; 特征损失

文献标志码: A **中图分类号:** TP391.41 **doi:** 10.3778/j.issn.1002-8331.1706-0436

1 引言

计算机断层扫描 CT (Computed Tomography), 磁共振成像 MRI (Magnetic Resonance Imaging) 技术为无创医疗提供方便, 辅助医生进行诊断, 清晰的医学图像可以提供更加丰富的病灶信息, 提高诊断的准确率。但是由于成像环境、成像系统和人为等因素的限制, 获取清

晰的医学图像并不那么容易。为了解决这样的计算机视觉问题, 可以借助超分辨率重建技术, 改善退化图像的质量, 提高图像的分辨率。

近年来, 超分辨率重建技术主要有两类方法: 一类是基于重建的方法; 另一类是基于学习的方法。基于重建的方法, 是通过低分辨率图像的获取过程进行建

基金项目: 四川省科技支撑计划资助项目 (No. 2015RZ0008); 四川省教育厅重点项目 (No. 15ZA0186)。

作者简介: 邢晓羊 (1991—), 男, 硕士生, 研究领域为图形图像, 机器学习; 魏敏 (1978—), 男, 博士, 副教授, 研究领域为图像处理及应用、虚拟现实及 3D 仿真技术, E-mail: weimin@cuit.edu.cn; 符颖 (1988—), 女, 博士, 副教授, 研究领域为图像处理及非参贝叶斯在图像复原中的应用术。

收稿日期: 2017-07-03 **修回日期:** 2017-08-29 **文章编号:** 1002-8331(2018)20-0202-06

CNKI 网络出版: 2018-02-06, <http://kns.cnki.net/kcms/detail/11.2127.TP.20180205.1504.010.html>

模, 利用正则化方法构造高分辨率图像的先验约束, 由低分辨率图像估计高分辨率图像, 重建在降质过程中丢失的高频信号, 最终将问题转化为约束条件下代价函数最优化的问题; 而基于学习的超分辨率重建方法, 其基本思想是通过学习获得高分辨率图像与低分辨率图像之间的映射关系。在这类方法中, 学习的过程是关键, 可以利用稀疏表示等理论进行学习, 学习结束就可以不依赖人的先验知识指导低分辨率图像进行重建。

伴随着信息化程度的提高和图形处理器计算能力提升, 图像数据的获取与处理变的容易, 从而基于学习的超分辨率重建方法受到了广泛关注。Yang 等^[1]对低分辨率与高分辨率图像块构成的图像库进行稀疏表示, 并通过联合训练的方法找到低分辨率与高分辨率图像块之间相对应的完备字典, 建立之间的联系; Rueda^[2], Wang 等^[3]人使用基于稀疏表示的方法从低分辨率脑部 MR 图像产生高分辨率脑部 MR 图像; 黄浩锋^[4], 白福栋^[5]也使用同样的方法针对不同类型的医学图像进行了重建; Dong^[6]等人建立了一个只有一个隐藏层的卷积神经网络 SRCNN (Super-Resolution Convolutional Neural Network), 把网络视为一个端到端的映射, 一端为低分辨率图像另一端为高分辨率图像, 获得了较好的自然图像超分辨率重建效果; Bahrami^[7]等人设计了一个五层的三维卷积神经网络, 从 3T (特斯拉) 脑部图像重建出类 7T (特斯拉) 脑部图像; Oktay^[8]等人基于残差网络从二维心脏 MR 图像序列重建出高分辨率的三维图像; 其他医学图像超分辨率方法, 如 Burgos^[9]提出一种局部图像相似性的方法从 MR 图像重建出 CT 图像; Bahrami^[10]提出了一种联合典型关联分析的方法, 使用 3T (特斯拉) MR 图像重建出 7T (特斯拉) MR 图像的方法。

2 已有方法存在的问题

2.1 棋盘样式伪影

超分辨率重建问题是解决由低分辨率图像重建高分辨率图像的问题, 其中低分辨率图像的获取方法一般是对高分辨率图像进行下采样, 经过下采样的图像作为重建的数据源, 原始高分辨率图像作为重建的目标。采样率大于原来获得该数字信号的采样率称为上采样, 上采样的主要目的是放大图像, 从而在更高分辨率的显示设备上显示。SRCNN 将图像的上采样作为训练卷积神经网络之前的图像处理, 在测试阶段也需要将图像进行同样上采样处理。这样事先将下采样得到的低分辨率图像进行上采样再用于卷积神经网络的训练是繁琐的, 上采样的过程是可以融入到卷积神经网络中, 从而不依赖固定的上采样插值函数, 将上采样的过程也作为网络可以学习的一部分, 使得训练好的网络具有更加普遍的适用性。

在卷积神经网络内实现图像的上采样, 常用的方法就是设置转置卷积^[11]层或子像素卷积层^[12]。转置卷积也叫反卷积, 但在使用转置卷积过程中, 会发生卷积不均匀导致图像某些位置的颜色比其他部位更深的问题^[13], 出现如图 1(b) 中明暗相交类似于棋盘格子的伪影, 这样的伪影在卷积核的大小不能被步长整除时更加明显; 子像素卷积的卷积核能被步长整除, 但是这种方法虽然有帮助, 但仍然容易产生类似于棋盘格子的伪影。




图1 棋盘格子样式的伪影

2.2 均方误差损失函数

对 $H \times W$ 大小的图像 I 和噪声近似图像 \hat{I} , $\hat{I} \in \mathbb{R}^{H \times W}$, $I_{i,j}$ 表示在图像 I 在位置 (i,j) 的像素值, 那么图像 I 和 \hat{I} 的逐像素均方误差定义为公式(1):

$$MSE = \frac{1}{HW} (\hat{I} - I)^2 = \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W (\hat{I}_{i,j} - I_{i,j})^2 \quad (1)$$

在使用卷积神经网络进行图像处理时, 使用 MSE 作为损失函数衡量输出图像与真实图像的差距, 如公式(2):

$$J(w) = \frac{1}{HW} (f_w(\hat{y}) - y)^2 \quad (2)$$

式中 \hat{y} 表示训练样本输入, y 表示训练样本标签, $f_w(\hat{y})$, $y \in \mathbb{R}^{H \times W}$, w 表示网络 f 中的权重, $f_w(\hat{y})$ 表示使用参数 w 的网络 f 对训练样本 \hat{y} 预测。

MSE 计算方法简单, 计算时图像可以理解为一个一维向量^[14], 没有考虑图像 I 和 \hat{I} 的空间信息, 所以使用 MSE 衡量两幅图像相似程度是不准确的。如图 2 中显示 5 个数字手写体图像, 其中 (a) 表示手写数字 3, (b) 表示手写数字 5, (c), (d) 分别表示 (b) 右移一位与右移两位, (e) 表示不同于 (b) 的手写数字 5。计算 (a)、(e) 与 (b) 的 MSE 值显示在表 1 中, 不同数字 (a) 与 (b) 的计算结果比相同数字的 (b) 与 (e) 的计算结果要小, 可是 (b) 与 (e) 在空间上更加相似, 这是不符合人的视觉感官的。此外, MSE 值对图像的形变是非常敏感的, 表 1 中 (c)、(d) 与 (b) 的 MSE 计算结果表明相同数字在位置上的变化引起 MSE 的变化是比较剧烈的, 在较小的图像上这样位置上的变化还可以用肉眼分辨, 但是在较大的图像上, 这样一个像素位的变化是不容易分辨的, 但它引起 MSE 的变化将更大, 这同样也不符合人眼的感官。




图2 数字手写体图像

表1 数字手写体图像的MSE

描述	MSE
不同数字:图2(a)与(b)	13 187.468 1
相同数字:图2(e)与(b)	13 933.928 6
图2(b)右移1位:图2(c)与(b)	4 478.762 8
图2(b)右移2位:图2(d)与(b)	8 957.525 5

使用均方误差损失函数来衡量模型预测值与真实值的平均值,把它看作是衡量模型在训练集上的表现,当模型在训练集上表现不好,那么损失越高。经过上面的分析,MSE不符合人的视觉感官,同时对图像的形变也是非常敏感的,所以单一使用MSE不能很好地衡量卷积神经网络输出图像与目标真实图像之间的感知差异。

3 基于特征损失的医学图像超分辨率重建

3.1 系统介绍

系统主要由两部分组成的:图像转换网络 f_w 和损失网络 ϕ ,结构图如图3。




图3 系统结构图

图3中虚线部分表示图像转换流程,这部分实现将低分辨率图像 \hat{y} 通过网络转换成高分辨率图像 $f_w(\hat{y})$,其中 f_w 是自定义的卷积神经网络。实线部分使用一个预先训练好的图像分类网络计算特征损失,损失网络 ϕ 中的权重在训练过程中是保持固定的,只有图像转换网络中的权重在训练中是在不断学习的。

3.2 图像转换网络

前馈神经网络将网络中各个神经元按接收信息的先后分为不同的组,每一组可以看作是一个网络层,每一层中的神经元接收前一层神经元的数输出作为自己的输入,再将自己的输出输入到下一层。整个网络中的信息是朝一个方向传播的。前馈网络可以看作一个通过简单非线性函数的多次组合,实现输入空间到输出空

间的复杂映射。

图像转换网络 f_w 是一个全连接前馈神经网络,全连接可以使网络在测试阶段使用任何大小的图像,不求网络的输入为固定大小。 f_w 实现的功能是将 $H/4 \times W/4$ 大小的低分辨率医学图像转换成 $H \times W$ 大小的高分辨率图像。在网络的设计中,网络超过一定深度,会出现梯度弥散,即使使用批归一化操作,也会导致很高的训练误差,解决问题的方法是在网络中添加输入与激活层的输出的快捷连接的残差块。残差块由 He^[15] 提出,思想是采用标准的前馈卷积神经网络,并添加一次跳过几层的连接,每次跳过产生残差块,跳过部分的计算结果添加到输入中作为输出结果,本文设计如图4的残差块结构,网络 f_w 包含五个这样的残差块。




图4 残差块结构图

网络 f_w 还包含两个(放大)卷积层,经过两次(放大)卷积层,图像就放大为输入大小的4倍。(放大)卷积层采用先调整网络中层的大小,例如使用最邻近内插法或双线性插值法,之后再行卷积操作。在设置上采样层的位置时,按照一般先放大后训练网络的思路,将上采样层放置在网络的前段,但这样的操作会导致后面网络层的计算量增大,所以合理的方式是将上采样层放置在网络的后段,使得在上采样层之前只是对小尺寸图像进行处理,直到最后上采样层再将其放大,减少计算量。

网络 f_w 除了最后一层的输出使用双曲正切函数(tanh)将输出图像的像素映射到0~255,其他卷积层都引入非线性激励函数(ReLu)。除第一个卷积层的卷积核大小为 9×9 ,其他卷积层的卷积核大小为 3×3 。详细参数显示在表2中。

3.3 损失网络

在图像分类任务中,一个网络训练好后,网络中的不同层对图像不同特征的抽象程度是不相同的。为了增加图像转换网络的输出与真实图像空间上的相似程度,引入一个预先训练好的用于图像分类的卷积神经网络 VGG16^[16],这个网络有着非常均匀的架构,从始至终仅执行 3×3 和 2×2 的卷积。为了更加直观地了解网络内部图像表示过程,使用图像本身的表示信息,将随机



图5 VGG16网络不同层的反向表示

表2 图像转换网络详细参数

层	参数	大小
输入	—	1×24×24
卷积层	卷积核 9×9, 滤波数 64, 步长 1	64×24×24
残差块	滤波数 64, 步长 1	64×24×24
残差块	滤波数 64, 步长 1	64×24×24
残差块	滤波数 64, 步长 1	64×24×24
残差块	滤波数 64, 步长 1	64×24×24
卷积层	卷积核 3×3, 滤波数 64, 步长 2	64×48×48
卷积层	卷积核 3×3, 滤波数 64, 步长 2	64×96×96
卷积层	卷积核 3×3, 滤波数 1, 步长 1	1×96×96

噪声作为初始解,反向表示卷进神经网络特征,将网络的不同层进行可视化^[17]。图5反向表示了VGG16网络中所有激活层(ReLu),从图中可以发现在网络的较低层图像内容和结构被很好地保存;在较高层中,图像的颜色、纹理结构都消失了,图像细节也消失了。

通过分析VGG16网络结构,图像经过VGG16较低层时,池化操作保存了图像主要内容信息,而图像绝对位置特征被弱化,利用这种特性,将超分辨率重建卷积神经网络的输出 $f_w(\hat{y})$ 与目标图像 y 再次输入VGG16网络中,使用 $f_w(\hat{y})$ 与 y 在VGG16较低层中的MSE作为损失函数,期望它们在VGG16中有相似的特征表示,增加网络的输出与目标图像空间上的相似性,不做单一的逐像素比较,这样损失函数定义为特征损失,计算方法如公式(3):

$$J(w) = \frac{1}{H_l W_l C_l} (\phi_l(f_w(\hat{y})) - \phi_l(y))^2 \quad (3)$$

式中, ϕ 表示预先训练好的VGG16网络, $l \in \{\text{Relu1_1}, \text{Relu1_2}, \dots, \text{Relu5_3}\}$,本实验 $l = \text{Relu2_2}$, $\phi_l(f_w(\hat{y}))$, $\phi_l(y) \in \mathbb{R}^{H_l \times W_l \times C_l}$, H_l 、 W_l 、 C_l 分别表示在VGG16中某一激活层输出的长、宽和通道数。

在有监督的机器学习任务中,可以通过优化目标函数生成高质量的图像,目标函数是用来估计模型的预测值与真实值之间的差异程度,它是一个非负数函数,优化目标函数就是找到参数 w 使得损失 J 最小。在超分辨率重建的应用中,使用公式(3)定义的损失函数训练卷积神经网络让网络输出 $f_w(\hat{y})$ 非常接近目标图像 y ,

但并不是让它们做到完全的匹配,只是视觉上 y 不太能区分,使得重建出来的图像更加符合人眼的视觉特征。在网络的训练的过程中,网络中 ϕ 的权重都是固定的,超分辨率重建网络 f_w 中的权重 w 在训练过程中是不断学习修正的,网络结构如图6。




图6 特征损失计算流程图

为了防止过拟合,通过损失函数添加total variation (总变差)正则化项,约束要优化的参数 w ,由此超分辨率重建的目标函数可以表示为公式(4):

$$J(w) = \frac{1}{H_l W_l C_l} (\phi_l(f_w(\hat{y})) - \phi_l(y))^2 + \lambda R_{tv}(f_w(\hat{y})) \quad (4)$$

式中 $\lambda = 10^{-3}$ 表示正则化因子,由于图像是离散分布的,使用有限差分近似替代^[17],对于图像 $x \in \mathbb{R}^{H \times W}$,有限差分定义为公式(5):

$$R_{tv}(x) = \sum_{i=1}^H \sum_{j=1}^W ((x_{i,j+1} - x_{i,j})^2 + (x_{i+1,j} - x_{i,j})^2)^{\frac{1}{2}} \quad (5)$$

式中, $x_{i,j}$ 表示在图像 x 置 (i,j) 的像素值。

3.4 网络优化方法

目标函数使用自适应矩估计随机优化方法^[18],它利用梯度的一阶中心矩估计和二阶中心矩估计动态调整每个参数的学习率,它的优点主要在于经过偏置校正后,每一次迭代学习率都有确定的范围,使得参数比较平稳。算法的主要步骤如下:

算法1 自适应矩估计算法流程

输入:随机优化目标函数 $J(w)$

初始化:

α :学习率 $\alpha = 0.001$

$\beta_1 = 0.9$, $\beta_2 = 0.999$:中心矩估计的指数衰减率

w_0 :化权重向量

$m_0 \leftarrow 0$:初始化一阶矩向量

$n_0 \leftarrow 0$:初始化中心矩向量

$t \leftarrow 0$:初始化迭代次数

$$\varepsilon = 10^{-8}$$

$$(1) t \leftarrow t + 1$$

$$(2) g_t \leftarrow \nabla_w J_t(w_{t-1}) : \text{计算第 } t \text{ 次迭代 } J(w) \text{ 的梯度}$$

$$(3) m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t : \text{更新有偏一阶矩估计}$$

$$(4) n_t \leftarrow \beta_2 \cdot n_{t-1} + (1 - \beta_2) \cdot g_t^2 : \text{更新有偏二阶矩估计}$$

$$(5) \hat{m}_t \leftarrow m_t / (1 - \beta_1^t) : \text{偏差修正}$$

$$(6) \hat{n}_t \leftarrow n_t / (1 - \beta_2^t) : \text{偏差修正}$$

$$(7) w_t \leftarrow w_{t-1} - \alpha \cdot \hat{m}_t / (\sqrt{\hat{n}_t} + \varepsilon) : \text{更新权重}$$

$$(8) \text{循环(1)至(7)直到满足最大迭代次数}$$

输出: w_t

4 实验与分析

4.1 实验方法

基于学习的超分辨率重建方法在应用于大型训练集时最有效,自然图像领域已经有许多大型训练集合,例如 ImageNet 等,但在医疗图像领域,大型数据集的获取是不易的。本次实验数据来自 35 位 20 岁至 59 岁健康成年人的脑部结构 T1(纵向弛豫)加权成像,每张图像的大小为 256×176 ,将图像分为两部分,一部分用作训练,另一部分用作测试。将训练部分的图像分割成 96×96 大小的图像块,这些图像块作为高分辨率的目标图像。对高分辨率图像进行标准差 $\sigma = 0.1$ 的高斯模糊,再使用双三次插值方法进行下采样,采样因子为 4,获得 24×24 大小的低分辨率图像块,这些块作为转换网络 f_w 的输入,经过 4 倍的放大和高分辨率目标图像一起输入损失网络 ϕ ,计算特征损失 $J(w)$ 。训练学习率为 0.001,批处理大小 4,迭代 20 万次,使用 GPU 加速训练。

对比实验之一使用 Dong 等人的 SRCNN^[6]方法,该方法使用三层卷积神经网络,包含 3 个卷积层,卷积核的大小依次为 9、1、5,训练数据来自自然图像检测比赛 (ILSVRC2013) 数据集,先将图像转换到 YCrCb 颜色空间,只用 Y 通道图像作为训练数据,网络的输入为 33×33 大小的低分辨率图像块,目标为 21×21 大小的高分辨率图像块,网络输出与目标图像块的均方误差作为损失函数,批处理大小是 128,学习率是 0.001。作为对比实验,修改 SRCNN 的输入块和目标块的大小实现 4 倍放大,网络输入为 32×32 大小的低分辨率图像块,目标为 20×20 大小的高分辨率图像块,详细参数如表 3,其他参数保持不变。对比实验还使用单一 MSE 作为损失函数,直接计算转换网络的输出与目标图像的 MSE,以此验证图像转换网络的有效性。最后使用传统的双三次插值进行比较。

4.2 结果与分析

评价图像重建质量方法主要有 PSNR(峰值信噪比)和 SSIM(结构相似性指标),本文采用这两种指标(公

表 3 用于对比实验 SRCNN 方法网络详细参数

层	参数	大小
输入	—	$1 \times 32 \times 32$
卷积层	卷积核 9×9 , 滤波数 64, 步长 1	$64 \times 25 \times 25$
卷积层	卷积核 1×1 , 滤波数 32, 步长 1	$32 \times 25 \times 25$
卷积层	卷积核 5×5 , 滤波数 1, 步长 1	$1 \times 20 \times 20$

式(6)和公式(7))来评价不同方法重建结果的质量。

$$PSNR = 10 \lg \frac{(2^n - 1)^2}{MSE} \quad (6)$$

$$SSIM = \frac{(2\mu_I\mu_{\hat{I}} + C_1)(2\sigma_{I\hat{I}} + C_2)}{(\mu_I^2 + \mu_{\hat{I}}^2 + C_1)(\sigma_I^2 + \sigma_{\hat{I}}^2 + C_2)} \quad (7)$$

式中, n 为每像素的比特数, μ_I , σ_I 表示原始图像 I 的平均值和方差, $\mu_{\hat{I}}$, $\sigma_{\hat{I}}$ 表示重建结果图像 \hat{I} 的平均值和方差, $\sigma_{I\hat{I}}$ 表示图像 I 与 \hat{I} 的协方差。 C_1, C_2 为常数。在 8 比特的图像上, PSNR 的典型值在 30~50 dB 之间, 数值越大表示失真越小。 SSIM 取值范围是 $[-1, +1]$, 图像对比质量越高, SSIM 越大。

因为网络 f_w 是全连接的,所以在测试时可以使用大小不相同的完整脑部图像进行测试。图 7(a)、(f)、(k)是来自不同人脑不同大小的完整图像,分别对测试图像(a)、(f)、(k)使用双三次插值(Bicubic)方法、SRCNN^[6]方法、单一使用 MSE 作为损失函数的方法和使用特征损失函数的方法进行测试,分别显示在图 7 中。表 4 为四种方法相应的 PSNR 和 SSIM 评价。从表 4 的计算结果看出,使用 MSE 作为损失函数和使用特征损失函数评价结果都比 SRCNN 和 Bicubic 的方法要好,说明本文所设计的实现医学图像的 4 倍放大图像转换网络 f_w 是有效的,从这两种方法重建结果的局部放大图也可以看出棋盘伪影现象得到了很高的改善;再比较这两种方法的评价,验证了本文提出的基于特征损失超分辨率重建的有效性。值得注意的一点是,使用特征损失方法,衡量图像之间的差异最终还是使用了 MSE,由公式(7)可知,计算测试结果的 PSNR 时也使 MSE,这一共同点可能是导致其 PSNR 较高的原因之一。

表 4 几种不同方法恢复图像的性能数值

测试图像	方法	PSNR/dB	SSIM
图 7(a)	Bicubic	25.657 0	0.752 7
	SRCNN	27.130 4	0.817 3
	MSE 损失方法	29.586 6	0.880 3
	特征损失方法	30.047 1	0.882 0
图 7(f)	Bicubic	25.095 4	0.767 4
	SRCNN	27.462 1	0.848 3
	MSE 损失方法	29.326 6	0.881 4
	特征损失方法	30.109 8	0.902 3
图 7(k)	Bicubic	24.034 0	0.735 1
	SRCNN	26.205 5	0.826 8
	MSE 损失方法	28.700 2	0.887 9
	特征损失方法	29.567 8	0.906 7




图7 实验结果图

从视觉上观察,MSE损失方法重建结果更加平滑,一些高频信息没有得到重建。在特征损失方法中,大部分图像细节被恢复,一些类似噪声的细节被平滑掉,更加符合人视觉感官,从视觉上验证了本文方法的有效性。

5 结束语

本文设计了一个前馈全连接卷积神经网络,实现了单幅医学图像的超分辨率重建,避免了使用卷积神经网络进行图像处理容易产生棋盘化伪影的问题。为了获得更好的图像感知效果,不使用单一的基于像素的均方误差损失函数,而是借助预先训练好的图像分类网络VGG16,从其较低层提取特征计算均方误差作为损失函数。实验结果从评价指标和视觉感知上都验证了方法的有效性,对测试图像的大小也有很好的鲁棒性。但是本文所提方法中图像转换网络的训练时间较长,针对人体不同部位的MR扫描图像,都需要采集一定量的图像作为训练集,并且都要经历完整的训练过程才能应用到实际中,应用范围受限。未来可以找到更好的衡量图像感知差异的损失函数并设计相应的网络结构进行超分辨率重建。

参考文献:

- [1] Yang J, Wright J, Huang T S, et al. Image super-resolution via sparse representation[J]. IEEE Transactions on Image Processing, 2010, 19(11): 2861-2873.
- [2] Rueda A, Malpica N, Romero E. Single-image super-resolution of brain MR images using overcomplete dictionaries[J]. Medical Image Analysis, 2013, 17(1): 113-132.
- [3] Wang Y H, Li J B, Fu P. Medical image super-resolution analysis with sparse representation[C]//2012 Eighth International Conference on Intelligent Information Hiding and Multimedia Signal Processing (IIH-MSP), 2012: 106-109.
- [4] 黄浩锋, 肖南峰. 基于组稀疏表示的医学图像超分辨率重建[J]. 计算机科学, 2015, 42(6A): 151-153.
- [5] 白福栋. 基于稀疏理论的医学图像超分辨率重建算法的研究与应用[D]. 杭州: 浙江大学, 2016.
- [6] Dong C, Loy C C, He K, et al. Image super-resolution using deep convolutional networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(2): 295-307.
- [7] Bahrami K, Shi F, Zong X, et al. Hierarchical reconstruction of 7T-like images from 3T MRI using multi-level CCA and group sparsity[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer, 2015: 659-666.
- [8] Oktay O, Bai W, Lee M, et al. Multi-input cardiac image super-resolution using convolutional neural networks[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. [S.l.]: Springer International Publishing, 2016: 246-254.
- [9] Burgos N, Cardoso M J, Thielemans K, et al. Attenuation correction synthesis for hybrid PET-MR scanners: application to brain studies[J]. IEEE Transactions on Medical Imaging, 2014, 33(12): 2332-2341.
- [10] Bahrami K, Shi F, Zong X, et al. Reconstruction of 7T-like images from 3T MRI[J]. IEEE Transactions on Medical Imaging, 2016, 35(9): 2085-2097.
- [11] Dumoulin V, Visin F A. A guide to convolution arithmetic for deep learning[J]. arXiv preprint arXiv:1603.07285, 2016.

(下转218页)

- [9] Xu H Y, Liu T T, Wang G T. Hybrid geodesic region-based active contours for image segmentation[J]. Computers & Electrical Engineering, 2014, 40(3): 858-869.
- [10] Vese L A, Chan T F. A multiphase level set framework for image segmentation using the Mumford and Shah model[J]. International Journal of Computer Vision, 2002, 50(3): 271-293.
- [11] 张少华. 自适应正则化活动轮廓模型[J]. 计算机应用, 2016, 36(6): 1709-1713.
- [12] 戚世乐, 王美清. 结合全局和局部信息的“两阶段”活动轮廓模型[J]. 中国图象图形学报, 2014, 19(3): 421-427.
- [13] 郑姗, 范慧杰, 唐延东, 等. 多相主动轮廓模型的眼底图像杯盘分割[J]. 中国图象图形学报, 2014, 19(11): 1604-1612.
- [14] Song H. Active contours driven by regularised gradient flux flows for image segmentation[J]. Electronics Letters, 2014, 50(14): 992-994.
- [15] Zhang K H, Zhang L, Song H H, et al. Active contours with selective local or global segmentation: a new formulation and level set method[J]. Image and Vision Computing, 2010, 28(4): 668-676.
- [16] 孙文燕, 董恩清, 曹祝楼, 等. 一种基于模糊主动轮廓的鲁棒局部分割方法[J]. 自动化学报, 2017, 43(4): 611-621.
- [17] 喻金桃, 郭海涛, 李传广, 等. 二叉树与多种活动轮廓模型相结合的遥感影像水边线提取方法[J]. 测绘学报, 2016, 45(9): 1104-1114.
- [18] 曹俊峰, 吴小俊, 陈素根. 基于改进符号压力函数的变分水平集图像分割算法[J]. 计算机科学, 2015, 42(8): 40-43.
- [19] 李宣平, 王雪. 模糊聚类协作区域主动轮廓模型医学图像分割[J]. 仪器仪表学报, 2013, 34(4): 860-865.
- [20] Li C M, Kao C Y, Gore J C, et al. Implicit active contours driven by local binary fitting energy[C]//IEEE Conference on Computer Vision and Pattern Recognition, Minnesota, 2007: 1-7.
- [21] Li C M, Xu C Y, Gui C F, et al. Distance regularized level set evolution and its application to image segmentation[J]. IEEE Transactions on Image Processing, 2010, 19(12): 3243-3254.
- [22] 王瑜, 闫沫. 基于 Wasserstein 距离和 SBFRLS 方法的活动轮廓模型图像分割算法[J]. 西安航空学院学报, 2016, 34(1): 68-73.

(上接 207 页)

- [12] Shi W, Caballero J, Huszár F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1874-1883.
- [13] Odena A, Dumoulin V, Olah C. Deconvolution and checkerboard artifacts[J]. Distill, 2016, 1(10).
- [14] Wang L, Zhang Y, Feng J. On the Euclidean distance of images[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2005, 27(8): 1334-1339.
- [15] He K, Zhang X, Ren S, et al. Deep residual learning

(上接 212 页)

- [8] Li F F, Perona P. A Bayesian hierarchical model for learning natural scene categories[C]//IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2005: 524-531.
- [9] Bosch A, Zisserman A, Muñoz X, et al. Scene classification via PLSA[C]//European Conference on Computer Vision, 2006: 517-530.
- [10] Lowe D G. Distinctive image features from scale-invariant key-points[J]. International Journal of Computer Vision, 2004, 60(2): 91-110.
- [11] Agrawal S, Verma N K, Tamrakar P, et al. Content based color image classification using SVM[C]//Eighth International Conference on Information Technology: New Generations. [S.l.]: IEEE Computer Society, 2011: 1090-1094.
- [12] Zheng S, Jayasumana S, Romera-Paredes B, et al. Conditional random fields as recurrent neural networks[C]//IEEE International Conference on Computer Vision (ICCV

for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.

- [16] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [17] Mahendran A, Vedaldi A. Understanding deep image representations by inverting them[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 5188-5196.
- [18] Kinga D, Adam J B. A method for stochastic optimization[C]//International Conference on Learning Representations (ICLR), 2015.
- [19] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.
- [20] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [21] Mahendran A, Vedaldi A. Understanding deep image representations by inverting them[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 5188-5196.
- [22] Kinga D, Adam J B. A method for stochastic optimization[C]//International Conference on Learning Representations (ICLR), 2015.
- [23] Krähenbühl P, Koltun V. Efficient inference in fully connected CRFS with Gaussian edge potentials[C]//Conference and Workshop on Neural Information Processing Systems (NIPS 2011), 2011: 109-117.
- [24] Lazebnik S, Schmid C, Ponce J. Beyond bags of features: spatial pyramid matching for recognizing natural scene categories[C]//IEEE Computer Society Conference on Computer Vision and Pattern Recognition. [S.l.]: IEEE Computer Society, 2006: 2169-2178.
- [25] Jia Yangqing, Shelhamer E, Donahue J, et al. Caffe: convolutional architecture for fast feature embedding[J]. Eprint Arxiv, 2014: 675-678.
- [26] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Computer Vision and Pattern Recognition, 2015: 3431-3440.
- [27] Chang C C, Lin C J. Libsvm: a library for support vector machines[M]. [S.l.]: ACM, 2011.